Data Engineering

Die ses Dokument enthält vertrauliche und firmeneigene Informationen der MAN. Es wird ausschließlich zu Auswertungszwecken zur Verfügung gestellt. Die ses Dokument und die darin enthaltenen Informationen dürfen nur mit ausdrücklicher vorheriger schriftlicher Genehmigung der MAN veröffentlicht, weitergegeben oder zu anderen Zwecken eingesetzt werden.



Statement of Work

Inhaltsverzeichnis

1	Ausschreibungsgegenstand	3
1.1	Ablauf der analytischen Vorhaben	3
1.2	Inhalt der analytischen Vorhaben	3
1.3	Abgrenzung	4
1.4	Menge/Umfang	5
2	Tätigkeitsprofile	7
2.1	Data Scientist	7
2.2	Data Engineer	8
2.3	Visualization	9
2.4	Architekt	. 10
2.5	Allgemeine Anforderungen	. 10
3	Technische und organisatorische Vorgaben	. 12
3.1	Technischer Aufbau der Big Data Plattform	. 12
3.2	Ablauf der Anwendungsentwicklung	. 13
3.3	Lizenzbedingungen	. 13
4	Tabellenverzeichnis	14

Statement of Work



1 Ausschreibungsgegenstand

Innerhalb der MTB werden derzeit zahlreiche potenzielle analytische Vorhaben und damit einhergehend relevante Datenquellen identifiziert. Diese in Zusammenarbeit mit den MAN-internen Experten aus den jeweiligen Fachbereichen, der IT und den Data Scientists und Data Engineers umzusetzen ist dabei Gegenstand der vorliegenden Ausschreibung.

1.1 Ablauf der analytischen Vorhaben

Analytische Vorhaben durchlaufen bei MAN verschiedene Reifegrade vom Proof-of-concept über die Pilot- und Prototypenphase bis hin zum produktiven Datenprodukt. Diese Phasen können je nach analytischem Vorhaben in Gänze oder einzeln umgesetzt werden.

Der Arbeitsmodus der analytischen Vorhaben entspricht in der Regel agiler Projektmethodik, kann jedoch auch im Ausnahmefall in klassischen Projektstrukturen gem. IT PEP der MTB erfolgen. Konkrete Festlegungen erfolgen nach Vorgabe von MAN für jedes analytische Vorhaben individuell.

Grundsätzlich haben in analytischen Vorhaben die Data Scientists und Data Engineers der MAN die fachliche Führung. Ihre Vorgaben sind einzuhalten, allerdings können und soll en selbstredend eigene alternative Vorschläge mit eingebracht werden. Das MAN-interne Mitarbeiter den externen Kollegen unterstellt sind ist allerdings nicht anzunehmen.

1.2 Inhalt der analytischen Vorhaben

Hauptbestandteil der analytischen Vorhaben sind zunächst deskriptive Datenanalysen für unterschiedliche Fachbereiche der MAN. Darüber hinaus kommen dann auch komplexere Algorithmen aus dem Bereich Machine Learning zum Einsatz.

Bei den zugrundeliegenden Daten handelt es sich hauptsächlich um relationale Tabellen¹. Dies können beispielsweise Telematikdaten, Werkstatt-informationen oder Vertriebsdaten aus unterschiedlichen Quellsystemen (DB2 HOST, SAP, ORACLE DB, CSV/XLS, etc.) sein. Bei Bedarf müssen aber auch semi- und unstrukturierte Informationen bearbeitet werden können.

Für neue analytischen Vorhaben müssen in den meisten Fällen neue Datenquellen angebunden werden und Daten aufbereitet und gespeichert werden. Die Entwicklung permanenter Schnittstellen in Realtime oder im Batch kann somit auch Bestandteil eines analytischen Vorhabens sein. Dies inkludiert nicht nur die Programmierung der Schnittstellen oder die Konfiguration von Pipelines sondern ebenso die Dokumentation der Schnittstellen sowie die technische Abstimmung mit allen betroffenen Bereichen (z.B. IT Ansprechpartner des Quellsystems, Verantwortliche für Backend, IT Security, etc.).

Nachdem es Ziel der analytischen Vorhaben ist, diese im Arbeitsalltag der Fachbereiche produktiv einzusetzen, ist die Produktivmachung ein weiteres wichtiges Themenfeld, welches in den Vorhaben umzusetzen ist. Dabei wird besonderes Augenmerk daraufgelegt, dass...

- die Entwicklung des Quellcodes abgeschlossen ist
- eine Bewertung durch IT-Security, Datenschutz, Legal und Betriebsrat erfolgt ist

¹ Daten werden derzeit in unterschiedlichen Formaten in S3 gespeichert und sind teilweise als Tabellen in Athena verfügbar



Statement of Work

- erforderliche Daten aus Schnittstellen kommen
- relevante Schnittstellen dokumentiert sind
- das Vorhaben in Betriebs- und Anwenderhandbuch beschrieben ist
- eine Architekturbeschreibung und –bewertung erfolgt ist
- eine CI-Strecke implementiert ist
- eine ausreichende Test-Coverage wie auch Code Qualität sichergestellt ist
- eine Betrachtung der Performance-Bedarfe erfolgt ist
- Abhängigkeiten zu anderen Systemen / Packages und Prerequisites erfasst sind
- der Betrieb bei den Betriebspartnern angemeldet und übergeben wurde
- Monitoring und Logging implementiert wurden
- Code von Schnittstelle und Applikation auf der Produktiven Umgebung laufen

Zum Zwecke der Nachhaltigkeit, Pflege der produktiven Datenprodukte und Betreibbarkeit wird großen Wert auf eine nützliche Dokumentation nach Vorgaben von MAN und die Einhaltung definierter Qualitätsstandards gelegt.

Auch ist es erforderlich, dass die Entwicklung im Rahmen analytischer Vorhaben auf der von MAN genutzten und vorgegeben Entwicklungsumgebung erfolgt, damit die Ergebnisse später wart- und veränderbar sind. Sollten Erweiterungen dieser Entwicklungsumgebung erforderlich sein, sind diese mit MAN abzustimmen. Die Umsetzung dieser Änderung kann in der Folge ein eigenes analytisches Vorhaben werden.

1.3 Abgrenzung

Explizit nicht im Umfang dieser Ausschreibung sind nachfolgend aufgelistete Themen, die dennoch in engem Verhältnis zum Gegenstand der Ausschreibung stehen:

- Betrieb der Big Data Plattform (Hardware und Betriebssystem)
- Betrieb weiterer Software der Big Data Plattform
- Betrieb externer Daten-Schnittstellen zu Quellsystemen
- Betrieb des Datenproduktes aus den analytischen Vorhaben

All diese Komponenten werden durch separate Provider betrieben. Der Auftraggeber geht jedoch davon aus, dass mit diesen Providern eng und im Sinne des Auftraggebers zusammengearbeitet wird.







1.4 Menge/Umfang

Die Tätigkeit lässt sich dabei in sieben unterschiedliche Tätigkeitsprofile zusammenfassen welche auch Grundlage des angefragten Angebots sein soll. Die Stufe "Einfach" beschreibt dabei einen Mitarbeiter mit einer Berufserfahrung bis zu drei Jahren. Bei einer Berufserfahrung von mehr als drei Jahren kann der Mitarbeiter als "Senior" bzw. "Komplex" eingestuft werden.

Die analytischen Vorhaben unterscheiden sich sehr stark in Ihrer Komplexität. Daher kann keine generische Aussage zu den einzelnen Abrufen getätigt werden. Indikativ kann jedoch von folgenden maximalen Mengen pro Jahr ausgegangen werden:

Anwendungsentwicklung	Geschätze Mengen in PT*			
Skill Level	Jahr 1	Jahr 2	Jahr 3	Gesamt
C2 Senior Architecture (komplex)	800	880	968	2.648
C3 Architecture (einfach)	800	880	968	2.648
C3 Senior Data Science (komplex)	800	880	968	2.648
C4 Data Science (einfach)	800	880	968	2.648
C3 Senior Data Engineering (komplex)	7.200	7.920	8.712	23.832
C4 Data Engineering (einfach)	1.600	1.760	1.936	5.296
C4 Senior Data Visualisierung (komplex)	400	440	484	1.324
C5 Data Visualisierung (einfach)	400	440	484	1.324
A0 Sonderthemen (Technologieberater)	400	440	484	1.324
A2 Projektleiter	640	704	774	2.118
A4 Beratung (Standard)	800	880	968	2.648
Summe Stundenkontingent pro Jahr	14.640	16.104	17.714	48.458

Tabelle 1: Tätigkeitsprofile und jährliche Mengengerüste

Einmalig wird eine Einarbeitung in die gegebene Big Data Plattform angeboten, für die je Skill Level C2 – C5 ein Aufwand von 5 Tagen² verrechnet werden kann (in Summe also 20 PT). Weitere Einarbeitungsaufwände gehen zu Lasten des externen Dienstleisters.

2

² Mittelwert zwischen Stufe "Einfach" und "Komplex"



Statement of Work

Zusätzlich werden in Tabelle 2 die Anteile für Nearshore (NS)- und Offshore (OS)-Tätigkeiten der einzelnen Skill Level angeführt (nähere Details zu Nearshore und Offshore siehe Servicevertrag). Der Offshore-Anteil ist nicht verpflichtend und kann auch in einem Nearshore-Standort erbracht werden. Der IT-SERVICEPARTNER muss jedoch im Falle von Offshore-Tätigkeiten, die Verfügbarkeit zu den im Servicevertrag definierten Servicezeiten (09:00-15:00 cet) sicherstellen.

Anwendungsentwicklung	Leistungserbringungsort		
Skill Level	Nearshore	Offshore	
C2 Senior Architecture (komplex)	100%	0%	
C3 Architecture (einfach)	50%	50%	
C3 Senior Data Science (komplex)	50%	50%	
C4 Data Science (einfach)	20%	80%	
C3 Senior Data Engineering (komplex)	50%	50%	
C4 Data Engineering (einfach)	25%	75%	
C4 Senior Data Visualisierung (komplex)	50%	50%	
C5 Data Visualisierung (einfach)	20%	80%	
A0 Sonderthemen (Technologieberater)	100%	0%	
A2 Projektleiter	50%	50%	
A4 Beratung (Standard)	100%	0%	

Tabelle 2: Anteil des Leistungserbringungsorts pro Skill Level





2 Tätigkeitsprofile

Die konkreten Tätigkeiten der C-Skillstufen aus Tabelle 1 (Tätigkeitsprofile und jähriche Mengengerüste) sind in weiterer Folge im Detail beschrieben.

2.1 Data Scientist

Kenntnisse Sicherer Umgang mit den Programmiersprachen Apache Spark, Python, R. Scala, Java Verständnis statistischer Methoden und lernender Systeme Tiefe Kenntnisse von Data Mining und Machine Learning, Deep Learning, Clustering, Recommendation, Classification (Komplex) Mehrjährige Erfahrung im Bereich Datenanalyse und multivariate Statistik (Komplex) Erfahrung in der Datenaufbereitung für spezifische Anwendungsfälle Grundlegende Expertise im Bereich Software Engineering für die Serienreifmachung produktiver Datenprodukte (inkl. Testen, Deployment, Code Qualität Logging, Monitoring, Betrieb) Kenntnisse des Coudera Hadoop Stack Detaillierte Kenntnisse agiler Softwareentwicklung nach Scrum Fachliche Automotive Branchen Kenntnisse Aufgaben Laden von Daten auf die Big Data Plattform Zielgerichtete Aufbereitung von Daten für spezifische Use Cases und Erstellen von Daten-Profilen • Explorative Analyse der Daten Zielgerichtete Datenanalysen hinsichtlich definierter Fragestellungen Projektmanagement und Beratung der Fachbereiche hinsichtlich Umsetzbarkeit und Interpretation spezieller Fragestellungen Serienreifmachung von Use Case für die stabile produktive Nutzung Koordination der Aktivitäten des Dienstleisters (nur komplex) Relevante Apache Spark (vertiefte Kenntnisse) Tools R Studio (vertiefte Kenntnisse) Hue, Hive, Impala (vertiefte Kenntnisse) Jupyter Notebooks (vertiefte Kenntnisse) Gitlab (vertiefte Kenntnisse) Tableau, Shiny, Bokeh (Basiswissen) AirFlow (Basiswissen)

Tabelle 3: Beschreibung Tätigkeitsprofil Data Scientist

Redhat Linux

Docker

(Basiswissen)

(Basiswissen)





2.2 Data Engineer

Kenntnisse

- Sicherer Umgang mit den Programmiersprachen Apache Spark, Python, R, Scala, Java und Kotlin
- Verständnis der AWS Cloud Ingestion Lösungen
- Verständnis für effiziente Datenverarbeitung und Haltung in S3 und Datenbanken (On-Prem und Cloud)
- Kenntnis relevanter Quellsysteme und deren Datentypen und –Strukturen
- Kenntnis in der Umsetzung von Batch- und Realtime-Schnittstellen
- Erweiterte Expertise im Bereich Software Engineering für die Serienreifmachung produktiver Datenprodukte (inkl. Testen, Deployment, Code Qualität Logging, Monitoring, Betrieb)
- Erfahrung in der Entwicklung verteilt-arbeitender Systemen
- Erfahrung in Docker basierendem Deployment und bzgl. Resource Manager
- Erfahrung in CI/CD Pipelines und Tools
- Kenntnis und praktische Erfahrung mit Workflow Managers
- Detaillierte Kenntnisse agiler Softwareentwicklung nach Scrum
- Fachliche Automotive Branchen Kenntnisse

Aufgaben

- Laden von Daten auf die Big Data Plattform
- Zielgerichtete Aufbereitung von Daten für spezifische Use Cases und Erstellen von Daten-Profilen
- Entwicklung von betriebsreifen Datenpipelines
- Koordination der Aktivitäten des Dienstleisters (nur komplex)

Relevante Tools

Redhat Linux (vertiefte Kenntnisse) Docker (vertiefte Kenntnisse) Kubernetes (vertiefte Kenntnisse) (vertiefte Kenntnisse) Spark AWS S3 (vertiefte Kenntnisse) Airflow (vertiefte Kenntnisse) AWS Glue (vertiefte Kenntnisse) • AWS Data Pipelines (vertiefte Kenntnisse) Kafka, Confluent Connectors (vertiefte Kenntnisse) AWS Kineses (vertiefte Kenntnisse) ELK. (vertiefte Kenntnisse) GitLab or Jenkins (Basiswissen) Artifactory (Basiswissen) IntelliJ / Eclipse (Basiswissen)

Tabelle 4: Beschreibung Tätigkeitsprofil Data Engineer





2.3 Visualization

Kenntnisse	 des Auftraggebe Fähigkeit durch v Begeisterung be schiedlichen Hin Erfahrung im Be Script, D3) für Detaillierte Kenn 	 des Auftraggebers Fähigkeit durch verschiedene Arten der Visualisierung Verständnis und Begeisterung bei Angehörigen verschiedenster Fachbereiche mit unter- schiedlichen Hintergrundwissen zu wecken Erfahrung im Bereich interaktiver Datenvisualisierung (z. B. mit Java Script, D3) für Webseiten Detaillierte Kenntnisse agiler Softwareentwicklung nach Scrum 		
Aufgaben	Darstellung kom teraktive GrafikeErstellung aussaAufbereitung erz	Storyboards mit den Auftraggebern plexer Analyseergebnisse in leichtverständliche und ingekräftige Datenvisualisierungen ielter Ergebnisse in Management-tauglicher CI-konforund PDF Präsentationen und Dokumentationen		
Relevante Tools	ShinyBokehTableauJava ScriptSAP LumiraSAP BI	,		

Tabelle 5: Beschreibung Tätigkeitsprofil Visualization





2.4 Architekt

Kenntnisse	 Erfahren in der Entwicklung/Umsetzung von Big Data-/BI-Architekturen Kenntnisse der Cloudera Hadoop und AWS-spezifischen Applikationen und Persistenzlösungen Entwicklung von On-premise und Cloud-Infrastrukturen (AWS) Kompetenz in Datenbanken und der Entwicklung verteilter Systeme Bewusstsein für Anforderungen der IT-Sicherheit Kenntnisse in Projektmanagement und Aufbau und Management von Betrieb (Applikation und Plattform) Detaillierte Kenntnisse agiler Softwareentwicklung nach Scrum Fachliche Automotive Branchen Kenntnisse 		
Aufgaben	Entwicklung von Architekturen analytischer Vorhaben Abstimmung der Architekturen von Applikation und Plattform Ableiten von Anpassungsbedarfen der Plattform-Architektur und der deren Umsetzung Planen von Projektvorhaben und deren Koordination		
Relevante Tools	 LDAP, Kerberos IT Security protocols like TLS, SSL, etc. Redhat Linux AWS, Azure Mesos, Marathon Oracle, SQL AWS S3 Dynamo DB AWS Glue AWS EMR AWS Data Pipeline Microsoft Visio, Powerpoint Docker, VMWare Kafka 	(vertiefte Kenntnisse) (Basiswissen) (Basiswissen) (Basiswissen)	

Tabelle 6: Beschreibung Tätigkeitsprofil Architect

Diese Übersicht der zuvor genannten Tätigkeitsprofile ist dabei indikativ zu verstehen und erhebt nicht den Anspruch auf Vollständigkeit.

2.5 Allgemeine Anforderungen

Der Auftraggeber legt besonderen Wert darauf, dass die eingesetzten Experten sich mit den folgenden Grundwerten identifizieren können bzw. folgende Erfahrungen mitbringen:

- Erfahrung in agilen Projekten und Arbeiten nach Scrum (Zertifizierung und praktische Erfahrung vorhanden)
- Ordentliche Dokumentation von Prozessen und Plattform
- Erfahrungen in der Steuerung und Leitung von Projekten
- Erfahrungen im Umgang mit Risiko/Unsicherheiten

MAR

MAN Truck & Bus SE

Statement of Work

• Einbringen eigener Ideen/Lösungsalternativen

Es wird erwartet, dass der Auftragnehmer über Lösungserfahrung für die Umsetzung von analytischen Vorhaben verfügt. Außerdem ist die Bereitschaft die VW- und MAN-Standards einzuhalten ein absolutes Muss (z.B. MAN-Projektstandards) und sich in etwaige bestehende Vorarbeiten einzudenken.



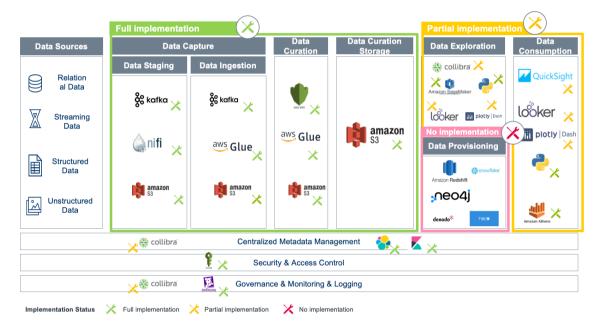


3 Technische und organisatorische Vorgaben

Eine detaillierte Beschreibung wird aus Gründen der Geheimhaltung nur nach Vertragsvergabe zur Verfügung gestellt. Eine kurze Zusammenfassung finden Sie nachfolgend. Die hier beschriebenen Entwicklungsumgebung und –vorgaben sind als verbindlich gesetzt.

3.1 Technischer Aufbau der Big Data Plattform

Die Big Data Plattform besteht im Wesentlichen aus den folgenden Bereichen, die sich technisch gesehen in unterschiedlichen AWS Account befinden.



Um ein analytisches Vorhaben umzusetzen, ist nötig entsprechende Datenquellen anzubinden, dass kann u.a. eine relationale Datenbank, eine Streaming-Quelle, strukturierte oder unstrukturierte Dateien sein. Die Datenquellen können sich innerhalb der Amazon Plattform oder auf MAN on-prem Servern befinden. Es existiert ein Staging-bereich der verschiedenen Technologien verwenden, wie z.B. S3 oder Nifi für die Batch- und Kafka für die Streaming-Verarbeitung.

Von Staging-bereich gelangen die Daten in einen sogenannten Ingestion-bereich. Hier kommen S3 und Glue für die Batch- und Kafka connect für die Streaming-Verarbeitung zum Einsatz. In diesem Bereich befinden sich Rohdaten.

Ein für ein analytisches Vorhaben benötigte standardisierte Datenformat wird nach diversen Aufbereitungsschritten mit Glue in S3 gespeichert. Zur Standardisierung gehört zum Beispiel die Einhaltung von Datenschutzvorgaben, wie das Entfernen von persönlich identifizierbaren Informationen oder das Maskieren entsprechender Daten. Hier wird vom AUFTRAGNEHMER verlangt, dass Ihre Mitarbeiter in diesem Bereich geschult und sensibilisiert sind.

Damit es für neue analytische Vorhaben einfacher ist relevante Daten aufzuspüren und wieder zu verwenden, muss ein Datenkatalog aufgebaut werden. Hier kommt das Werkzeug Colibra zum Einsatz, dass auch als übergreifendes Tool zum zentralisierten Metadata Management zum Einsatz kommt und im Bereich Data Governance eingesetzt wird.

Im Bereich Data Exploration geht es weiterhin darum bedeutungsvolle Daten zu extrahieren. Dazu benutzen wir in der Regel Sagemaker und der Einsatz von neuen Werkzeugen ist geplant.



Statement of Work

Die beiden Bereiche "Data exploration" und "Data provisioning" stellen zusammen die Grundlage dar, damit die Daten später konsumiert werden können. Dies kann simple Athena Tabellen, Quicksight Reports oder bis hin zu eigenen ständigen Applikationen erfolgen.

Alle in der Grafik grün markierten Werkzeuge müssen vom AUFTRAGNEHMER beherrscht werden und eine entsprechende Projekterfahrung muss nachgewiesen werden. Gerade im Bereich AWS sind die dem Skill-Profil entsprechenden "Associate Level" Zertifizierungen wünschenswert.

Für CI Pipelines und Artifactory wird eine Gitlab eingesetzt, dass von MAN gemanagt wird. Für das Logging und Monitoring stehen Werkzeuge wie Datadog bereit.

3.2 Ablauf der Anwendungsentwicklung

Die Anwendungsentwicklung im der Big Data Plattform ist nach agilen Methoden organisiert. Eine Änderung oder Modifizierung der angewandten Methoden, Zeitvorgaben sowie eine damit verbundene Anpassung der organisatorischen Vorgaben kann der AUFTRAGGEBER zu jeder Zeit entsprechend seinen betrieblichen Anforderungen vornehmen. Der AUFTRAGNEHMER sichert zu, entsprechende Anpassungen mitzutragen und unter Vermeidung von Einschränkungen des IT-Service entsprechend umzusetzen.

Die Anwendungsentwicklung wird im Rahmen von Sprints erbracht, die jeweils zwei (2) Wochen umfassen. In jeden Sprint werden Userstories in einer Mischform der beiden Vorgehensmodelle Scrum und Kanban vom AUFTRAGNEHMER in einem Team abgearbeitet, dass aus mehreren Dienstleistern bestehen kann. Scrum dient dabei, um Userstories entsprechend der Roadmap-Planung abzuarbeiten. Kanban wird zum Abarbeiten von operativen Tätigkeiten benutzt, wie das Fixen von Bug, das Anlegen von Usern und das Freischalten von Zugriffsrecten.

Der AUFTRAGNEHMER hat im Rahmen der des jeweiligen Vorhabens für einen regelmäßigen Wissensaustausch zwischen den eingesetzten Personen zu sorgen. Dies hat über geeignete Meetings sowie Schulungskonzepte zu erfolgen. Der AUFTRAGNEHMER ist verpflichtet keine Informationen einen anderen Dienstleister zurückzuhalten.

3.3 Lizenzbedingungen

Die allgemeinen Einkaufsbedingungen für die IT ebenso wie die IT-Sicherheitsrichtlinien sind selbstredend auch für analytische Vorhaben verbindlich und auf www.wwgroupsupply.de in Englisch und Deutsch veröffentlicht. Diese inkludieren u.a. auch die aktuell gültigen Lizenzbedingungen.



Statement of Work

4 Tabellenverzeichnis

Tabelle 1: Tätigkeitsprofile und jährliche Mengengerüste	. 5
Tabelle 2: Anteil des Leistungserbringungsorts pro Skill Level	. 6
Tabelle 3: Beschreibung Tätigkeitsprofil Data Scientist	. 7
Tabelle 4: Beschreibung Tätigkeitsprofil Data Engineer	. 8
Tabelle 5: Beschreibung Tätigkeitsprofil Visualization	. 9
Tabelle 6: Beschreibung Tätigkeitsprofil Architect	10